20 projets de science des données orientés finance, banque et FinTech

Public : licence avancée, master, reconversion professionnelle
Durée indicative : 2 à 4 semaines par projet
Outils : Python, pandas, NumPy, scikit-learn, matplotlib, Google Colab

Tableau récapitulatif

N°	Projet	Type d'apprentissage	Modèles / méthodes proposés	Difficulté	Source de données
1	Prédiction du défaut de crédit	Classification	Régression logistique, Random Forest, Gradient Boosting	Intermédiaire	UCI — Default of Credit Card Clients
2	Scoring et décision d'octroi de crédit	Classification	Régression logistique, Random Forest, analyse des coûts	Intermédiaire	UCI — Statlog German Credit
3	Détection de fraude bancaire	Classification déséquilibrée / anomalies	Régression logistique, Random Forest, Isolation Forest	Avancé	OpenML — Credit Card Fraud
4	Prédiction des faillites d'entreprises	Classification	Régression logistique, SVM, Random Forest	Avancé	UCI — Polish Companies Bankruptcy
5	Prédiction de souscription bancaire	Classification	Régression logistique, Random Forest, Gradient Boosting	Débutant	UCI — Bank Marketing
6	Analyse des demandes de crédit	Classification	KNN, arbre de décision, Random Forest	Débutant	UCI — Credit Approval
7	Détection de faux billets	Classification	Régression logistique, SVM, arbres	Débutant	UCI — Banknote Authentication
8	Évaluation du risque de solvabilité	Classification	Régression logistique, Random Forest, Gradient Boosting	Avancé	UCI — Taiwanese Bankruptcy Prediction
9	Prévision des taux d'intérêt	Régression temporelle	Persistance, Ridge, Gradient Boosting	Intermédiaire	FRED — DGS10
10	Prévision du taux de change EUR/USD	Régression temporelle	Marche aléatoire, Ridge, Random Forest	Avancé	FRED — DEXUSEU

N°	Projet	Type d'apprentissage	Modèles / méthodes proposés	Difficulté	Source de données
11	Prévision de volatilité boursière	Régression temporelle	Volatilité historique, Ridge, Gradient Boosting	Avancé	FRED — SP500
12	Prévision du chiffre d'affaires par client	Régression	Moyenne historique, Ridge, Random Forest	Intermédiaire	UCI — Online Retail II
13	Segmentation des clients selon leur valeur financière	Clustering	K-means, CHA, mélanges gaussiens	Débutant	UCI — Online Retail
14	Détection des transactions financières atypiques	Détection d'anomalies	Isolation Forest, LOF, One-Class SVM	Avancé	OpenML — Credit Card Fraud
15	Segmentation du risque financier des entreprises	ACP / clustering	ACP, K-means, CHA, GMM	Intermédiaire	UCI — Taiwanese Bankruptcy Prediction
16	Détection de régimes boursiers	Clustering temporel	K-means, mélanges gaussiens, ACP	Avancé	FRED — SP500, DGS10
17	Détection de comportements d'achat inhabituels	Détection d'anomalies	Isolation Forest, DBSCAN, seuils robustes	Intermédiaire	UCI — Online Retail II
18	Optimisation d'une campagne bancaire	Classification et décision	Régression logistique, Gradient Boosting, analyse du coût	Intermédiaire	UCI — Bank Marketing
19	Tableau de bord de risque de crédit	Transversal : analyse + classification	Régression logistique, Random Forest, calibration	Intermédiaire	UCI — Statlog German Credit
20	Analyse des cycles économiques et financiers	Transversal : ACP / clustering	ACP, K-means, mélanges gaussiens	Avancé	FRED — T10Y2Y, DGS10

Projets recommandés selon le niveau

- **Débutant :** 5, 6, 7 et 13.
- **Intermédiaire :** 1, 2, 9, 12, 15, 17, 18 et 19.
- **Avancé :** 3, 4, 8, 10, 11, 14, 16 et 20.

Consignes pédagogiques communes

1. Formuler une question précise et justifier son intérêt financier.
2. Charger les données depuis la source indiquée et documenter leurs dimensions et variables.
3. Effectuer le nettoyage, l'analyse exploratoire et les visualisations.
4. Construire un modèle de référence et au moins un modèle plus avancé.

5. Choisir un protocole d'évaluation approprié (stratifié, chronologique ou avec groupes).
6. Comparer les métriques : PR-AUC / ROC-AUC pour la classification, MAE / RMSE pour la régression, silhouette / stabilité pour le clustering.
7. Expliquer les limites : fuite de données, déséquilibre, dérive temporelle, représentativité et biais.
8. Livrer un notebook exécutable, des figures et un rapport synthétique.

Remarque : plusieurs projets réutilisent volontairement un même jeu de données pour traiter des problématiques distinctes. Pour les projets financiers temporels, éviter la séparation aléatoire entraînement/test. Ces projets sont pédagogiques et ne doivent pas servir directement à des décisions financières réelles.