Université Hassan 1er

École Nationale de Commerce et
de Gestion Settat

F8 : Peut-on battre la marche aléatoire ?

Prédiction du signe du rendement du S&P 500 et test de l'efficience du marché

Question : un modèle entraîné sur les rendements passés prédit-il le signe du rendement du lendemain mieux que le hasard ?

- **Tâche :** classification binaire (hausse ou baisse), avec référence de base.
- **Données :** FRED SP500, `https://fred.stlouisfed.org/graph/fredgraph.csv?id=SP500`.
- **Prétraitement :** rendements retardés, cible binaire, découpage chronologique.
- **Modèles :** prédiction de la classe majoritaire (référence), régression logistique, forêt aléatoire.
- **Métriques :** exactitude comparée à la référence, ratio de Sharpe d'une stratégie simulée après coûts.
- **Risque :** tester beaucoup de modèles et ne garder que le meilleur (*data snooping*) donne des résultats trompeurs.

— Réalisé par : **Nada Karmouni Tlemçani & Kawtar Ifri – G2 FINANCE**
— Encadré par : **Mr. Larhlimi**

Année universitaire 2026–2027

Sommaire

1 Introduction et problématique **2**

2 Données et prétraitement **2**

2.1 Source des données 2

2.2 Construction des variables 2

3 Méthodologie **3**

3.1 Découpage chronologique 3

3.2 Modèles comparés 3

3.3 Métriques et stratégie simulée 4

3.4 Contrôle du data snooping 4

4 Analyse du code **4**

4.1 Extraits clés 5

5 Évaluation finale sur le test **6**

6 Stratégie simulée après coûts **6**

7 Test de permutation (contrôle du data snooping) **7**

8 Verdict automatique **7**

9 Discussion **8**

10 Limites **8**

Conclusion **8**

Références **9**

1. Introduction et problématique

Selon la théorie de l'efficience des marchés (Fama, 1970), les prix contiennent déjà toute l'information disponible. Dans sa forme faible, regarder les prix passés ne permet donc pas de prévoir les prix futurs : le cours suit une marche aléatoire, comme un pile ou face. Si c'est vrai, aucun modèle entraîné sur l'historique des prix ne devrait faire mieux que le hasard.

Question de recherche donc s'impose : un modèle entraîné sur les rendements passés prédit-il le signe du rendement du lendemain mieux que le hasard ? En plus simple : en regardant les jours précédents, peut-on deviner si la bourse va monter ou baisser demain ?

Hypothèse nulle (H_0) : les variations passées n'aident pas à prédire le sens de la variation de demain. Le projet F8 teste si un modèle d'apprentissage automatique arrive à prouver le contraire. Pour cela, on le compare à une règle très simple et on évite de se laisser tromper par le hasard (le « data snooping », expliqué en 3.4).

2. Données et prétraitement

2.1 Source des données

Les données sont les prix de clôture quotidiens du S&P 500, l'indice des 500 plus grandes entreprises cotées aux États-Unis. Ils viennent de FRED, la base de données de la Réserve fédérale américaine. La série va du 7 novembre 2016 au 3 novembre 2026, soit 2 511 jours. Les jours fériés (bourse fermée) sont supprimés. FRED ne donne qu'une dizaine d'années de données quotidiennes, ce qui limite la précision de l'étude.

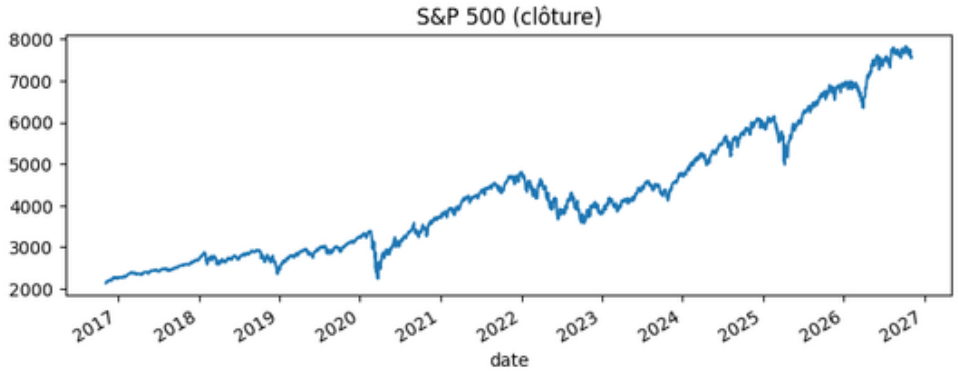


Figure 1. Évolution du S&P 500 (clôture quotidienne, 2016–2026)

À retenir : le marché monte globalement sur la période, malgré des chutes en 2020 et 2022. Résultat : environ 55 % des jours sont des hausses. Une règle qui répondrait toujours « hausse » aurait déjà 55 % de bonnes réponses. C'est la référence à battre.

2.2 Construction des variables

— **Rendement logarithmique :** la variation du prix d'un jour à l'autre, en pourcentage (calculée avec un logarithme : $r(t) = \ln\big(P(t)/P(t-1)\big)$).

— **Cible binaire :** la réponse que le modèle doit deviner. Elle vaut 1 si le marché a monté ce jour-là, 0 s'il a baissé ($y(t) = 1$ si $r(t) > 0$ (hausse), 0 sinon).
— **Variables explicatives :** ce que le modèle a le droit de voir : les variations des 5 jours précédents, plus la moyenne et l'agitation (écart-type) des variations sur 5 et sur 20 jours.

Point essentiel : ne pas tricher

Toutes ces informations sont décalées d'un jour : le modèle ne voit que le passé, comme un investisseur le matin avant l'ouverture de la bourse. S'il voyait le jour même, son score serait excellent mais faux.

Après suppression des premiers jours (qui n'ont pas assez d'historique), il reste 2 490 jours utilisables, dont 54,7 % de hausses.

3. Méthodologie

3.1 Découpage chronologique

On range les jours en trois blocs, du plus ancien au plus récent, comme pour un examen : un bloc pour s'entraîner, un pour choisir le meilleur modèle, un pour l'examen final. On ne mélange jamais les jours au hasard, car en vrai on ne connaît pas le futur : entraîner un modèle sur 2025 pour prédire 2023 serait de la triche.

Échantillon	Période	Taille	Part de hausses	Rôle
Apprentissage	07/12/2016 – 11/11/2022	1 494	54,8 %	Ajuster les modèles
Validation	14/11/2022 – 06/11/2024	498	54,4 %	Choisir le modèle
Test	07/11/2024 – 03/11/2026	498	55,0 %	Évaluation finale

Table 1. Découpage chronologique 60 % / 20 % / 20 %

3.2 Modèles comparés

— **Référence :** répondre toujours « hausse ». C'est le seuil à battre : un modèle utile doit faire mieux que cette règle sans intelligence, et pas seulement mieux que 50 %.
— **Régression logistique :** un modèle simple qui donne un poids à chaque information et en déduit une probabilité de hausse. On en teste 3 versions, plus ou moins prudentes (paramètre $C = 0{,}01\,;\ 0{,}1\,;\ 1$).
— **Forêt aléatoire :** un modèle plus flexible, composé de 300 petits arbres de décision qui votent. On en teste 3 versions, plus ou moins profondes (profondeur 2, 3 ou 5).

Cela fait 7 modèles au total. Ce nombre est fixé avant de regarder les résultats : c'est une précaution contre le *data snooping*.

3.3 Métriques et stratégie simulée

— **Exactitude :** le pourcentage de bonnes prédictions, comparé à celui de la référence. On vérifie aussi si l'écart peut s'expliquer par le hasard (grâce à la p-valeur, expliquée en section 5).

— **Stratégie simulée :** on achète quand le modèle prédit une hausse, on vend à découvert (on parie sur la baisse) quand il prédit une baisse. On déduit des frais de 0,05 % à chaque changement de position. Position longue (+1) si le modèle prédit une hausse, courte (−1) sinon. Un coût de 5 points de base est prélevé à chaque unité de variation de position.

— **Ratio de Sharpe :** le gain obtenu par unité de risque. Plus il est élevé, mieux c'est. On le compare à celui du *buy-and-hold* (acheter et garder sans rien faire), avec une marge d'incertitude.

— **Ratio de Sharpe annualisé** $= \dfrac{\text{moyenne}}{\text{écart-type}} \times \sqrt{252}$ des rendements quotidiens, taux sans risque supposé nul, comparé au *buy-and-hold*. Un intervalle de confiance à 95 % est obtenu par *bootstrap* par blocs (blocs de 20 jours) pour respecter l'autocorrélation de la volatilité.

3.4 Contrôle du data snooping

Si on teste beaucoup de modèles et qu'on garde seulement le meilleur, il paraîtra bon par chance. C'est comme si 100 personnes lançaient une pièce 10 fois : l'une d'elles fera 9 piles par pur hasard. Pour éviter ce piège, on a pris quatre précautions :

1. le nombre de modèles est fixé à l'avance ;
2. le modèle est choisi sur le bloc de validation, jamais sur le test ;
3. le bloc de test n'est utilisé qu'une seule fois, à la fin ;
4. un test de permutation mesure ce que donne la chance seule : on mélange au hasard les réponses d'entraînement et on refait toute la procédure, pour voir quel score obtiendrait quelqu'un qui n'a aucune information.

4. Analyse du code

Le notebook suit les étapes de l'étude. Le tableau résume ce que fait chaque bloc de code et pourquoi.

Étape	Ce que fait le code	Pourquoi
Imports et paramètres	Charge les outils, fixe une graine aléatoire (42), le coût (5 points de base) et le nombre de jours passés (5).	Obtenir les mêmes résultats à chaque exécution.
Chargement	Lit le fichier FRED, enlève les jours sans prix et garde une copie locale.	Pouvoir refaire l'analyse sans internet.
Variables et cible	Calcule les variations, les jours précédents, les moyennes et la cible hausse/baisse.	Le décalage des retards garantit que le modèle ne voit que le passé.
Découpage	Sépare les jours en 60 %, 20 % et 20 %, dans l'ordre du temps.	Ne jamais utiliser le futur pour apprendre.
Modèles	Crée les 7 modèles et les entraîne sur le premier bloc.	Un petit nombre de modèles, fixé à l'avance, limite le data snooping.
Sélection	Garde le meilleur modèle sur le bloc de validation.	Le test reste intact jusqu'à la fin.
Évaluation	Mesure le pourcentage de bonnes réponses sur le test et calcule les p-valeurs.	Savoir si l'écart avec la référence est du hasard.
Stratégie	Transforme les prédictions en achats ou ventes, retire les frais, calcule le Sharpe.	Une bonne exactitude ne suffit pas : il faut gagner de l'argent après frais.
Permutation	Refait 100 fois toute la sélection avec des réponses mélangées.	Voir ce que donne la chance seule.
Verdict	Teste si l'écart est significatif ET si la stratégie bat le buy-and-hold.	Deux conditions : une statistique, une économique.

Table 2. Structure du notebook et justification des choix

4.1 Extraits clés

Les trois lignes qui évitent la fuite d'information : le décalage des retards, la cible calculée sur le jour courant et le découpage chronologique.

```
for k in range(1, N_LAGS + 1):
    X[f"lag{k}"] = r.shift(k)      # info jusqu'a t-1 uniquement
y = (r > 0).astype(int)            # cible : signe du rendement de t
i1, i2 = int(.6*n), int(.8*n)      # decoupage dans l'ordre du temps
```

Ces trois lignes calculent le gain de la stratégie : $+1$ si on achète, -1 si on vend, moins les frais à chaque changement de position.

```
pos = pd.Series(np.where(pred == 1, 1.0, -1.0), index=ret.index)
turnover = pos.diff().abs().fillna(1.0)
return pos * ret - turnover * cout_bps/1e4
```

Dans le test de permutation, on mélange les réponses d'entraînement, on réentraîne les modèles, on choisit le meilleur sur la validation et on le note sur le test, comme dans la vraie procédure. On répète 100 fois.

5. Évaluation finale sur le test

Test binomial unilatéral : l'exactitude du modèle est-elle significativement supérieure à celle de la référence ?

Afin de savoir si le modèle prédit le signe du lendemain mieux que le hasard, on a testé une seule fois le modèle retenu sur la validation (régression logistique, $C = 0{,}01$) sur les 498 derniers jours (nov. 2024 → nov. 2026). On l'a comparé à la référence, qui prédit toujours « hausse », avec un test binomial et une correction de Bonferroni (une méthode statistique utilisée pour contrôler le risque de faux positifs (erreur de type I) lorsque l'on effectue plusieurs tests d'hypothèses simultanés sur un même ensemble de données). Le jeu de test n'est utilisé qu'une seule fois pour éviter le data snooping.

Résultat : le modèle fait 54,5 % d'exactitude contre 55,1 % pour la référence, soit un écart de −0,6 point. L'erreur-type est d'environ 2,2 points, donc l'écart est du bruit. Les p-valeurs sont de 0,62 (binomial) et de 1,00 (Bonferroni). Le modèle ne fait pas mieux que « toujours hausse ».

6. Stratégie simulée après coûts

Une prédiction peut être inexacte mais rentable, ou l'inverse. Il faut donc vérifier la valeur économique réelle, coûts inclus. On a transformé les prédictions en stratégie, long si hausse prédite et short sinon, avec 5 bps de coût par changement de position. On l'a comparée au *buy-and-hold*, avec un intervalle de confiance *bootstrap* par blocs sur le Sharpe.

Résultat :

- Le Sharpe est de 0,89 net, contre 0,90 pour le *buy-and-hold* : aucun gain.
- La rotation n'est que de 0,058 par jour : le modèle prédit presque toujours « hausse », donc la stratégie est quasiment du *buy-and-hold*.
- L'IC 95 % du Sharpe net est [−0,17 ; 2,04]. Il est très large et contient 0.

Le Sharpe net de la stratégie (0,843) est quasiment identique à celui du *buy-and-hold* (0,850). L'intervalle de confiance à 95 % du Sharpe net, [−0,25 ; 1,97], est très large et contient zéro : on ne peut pas affirmer que la stratégie crée de la valeur.

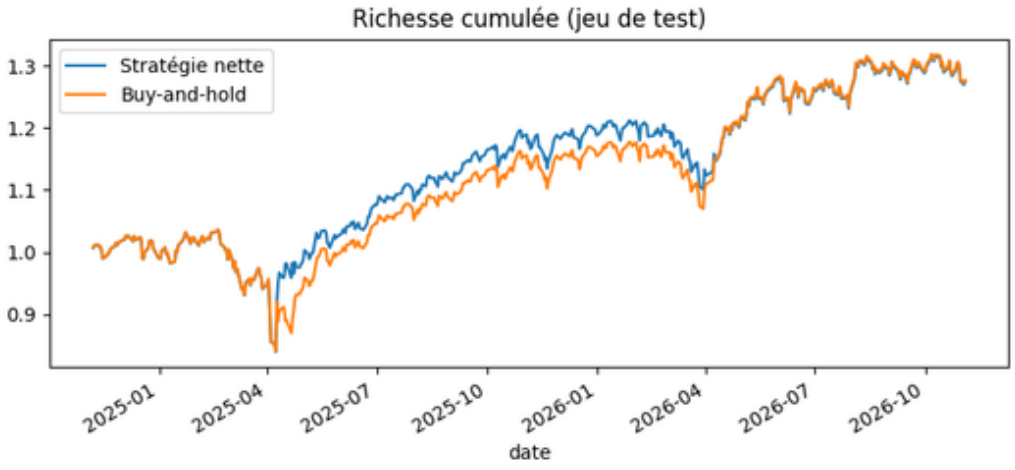


Figure 2. Richesse cumulée (jeu de test) : stratégie nette vs buy-and-hold

Lecture importante. La rotation moyenne n'est que de 0,058 par jour : la stratégie est presque toujours en position longue, car le modèle prédit presque toujours « hausse ». Elle reproduit donc le *buy-and-hold*, comme le montre la Figure 2 où les deux courbes sont très proches. Sa performance vient de la tendance haussière du marché sur 2024–2026, pas d'une capacité de prédiction. Les coûts de transaction réduisent le Sharpe de 0,889 à 0,843, ce qui illustre pourquoi un petit avantage brut disparaît facilement une fois les frais pris en compte.

7. Test de permutation (contrôle du data snooping)

Quand on teste plusieurs modèles et qu'on garde le meilleur, le score est optimiste. Ce test corrige ce biais. On a mélangé 100 fois les étiquettes d'apprentissage et rejoué toute la procédure (7 configurations, choix du meilleur sur la validation, évaluation sur le test). Cela donne la distribution de l'exactitude qu'un chercheur « sans information » obtiendrait par chance.

La Figure 3 montre la distribution de l'exactitude qu'obtiendrait, par pur hasard, la procédure complète de sélection. La valeur observée (0,5442) se situe au milieu de cette distribution et très en dessous de son 95e centile (0,5563). Le résultat n'est donc pas distinguable de celui d'un chercheur sans aucune information, ce qui est exactement ce que prédit l'efficience au sens faible.

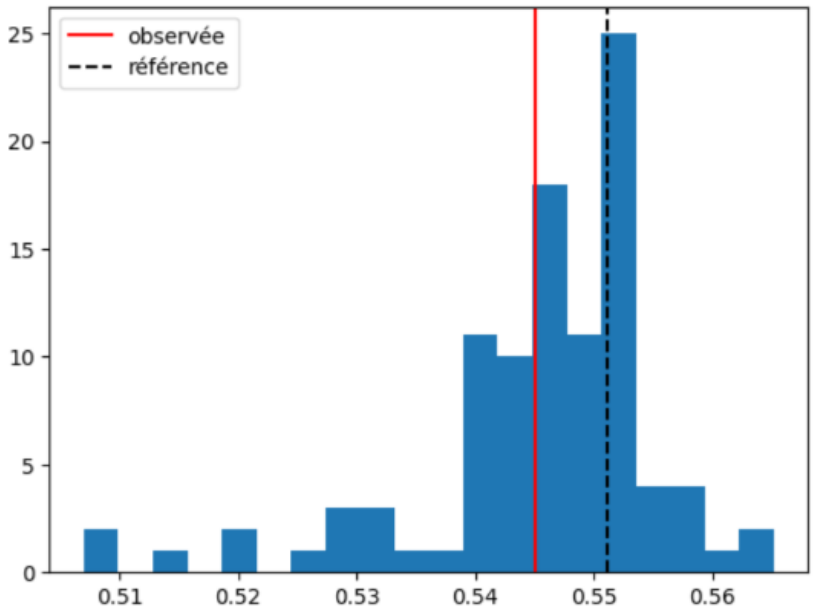


Figure 3. Distribution de l'exactitude sous permutation (100 répétitions)

8. Verdict automatique

On a croisé deux critères : écart d'exactitude significatif (binomial ET permutation) et stratégie supérieure au *buy-and-hold* avec un IC de Sharpe > 0.

Résultat : les deux critères sont `False`. On ne rejette pas l'hypothèse d'efficience faible :

aucun modèle ne bat la marche aléatoire de façon robuste, ni en exactitude, ni en rendement ajusté du risque.

9. Discussion

Les résultats sont cohérents avec l'efficience des marchés au sens faible : les rendements passés ne permettent pas de prédire le signe du rendement futur mieux que la simple fréquence historique des hausses. Il faut toutefois nuancer. Ce résultat n'est pas une preuve d'efficience ; il traduit l'absence de preuve contre elle, sur cet échantillon et avec ces variables.

Le surapprentissage observé sur les forêts aléatoires est instructif : la capacité d'ajustement ne crée pas de pouvoir prédictif quand le signal est faible par rapport au bruit. Un modèle performant en apprentissage mais pas en validation est un avertissement classique en finance quantitative.

Enfin, la stratégie « presque toujours longue » rappelle qu'il faut toujours comparer à une référence pertinente. Le Sharpe de 0,84 paraît attractif en soi, mais il s'explique entièrement par la tendance du marché : sans la comparaison avec le *buy-and-hold*, on aurait pu croire à tort que le modèle prédit quelque chose.

10. Limites

— **Puissance statistique limitée :** environ dix ans de données et un jeu de test de 498 jours. Avec une erreur-type d'environ 2,2 points, seul un écart important aurait pu être détecté ; un faible avantage réel resterait invisible.
— **Un seul indice :** le S&P 500 est très liquide et très surveillé, donc probablement parmi les marchés les plus efficients. Les conclusions pourraient différer pour des actifs moins liquides.
— **Variables limitées :** seuls les rendements passés sont utilisés. Le volume, des variables macroéconomiques ou la volatilité implicite pourraient contenir davantage d'information.
— **Coûts simplifiés :** un coût fixe de 5 points de base ne reflète ni l'écart achat-vente variable ni l'impact sur les prix.
— **Dépendance à la période :** le test couvre 2024–2026, une période de marché haussier qui favorise le *buy-and-hold*.

Conclusion

Dans les conditions de cette étude, aucun des modèles testés ne bat la marche aléatoire de façon robuste. Le modèle retenu atteint une exactitude de 54,4 % contre 55,0 % pour la référence, avec des p-valeurs de 0,62 (binomiale), 1,00 (Bonferroni) et 0,65 (permutation). Après coûts, la stratégie obtient un Sharpe de 0,84 contre 0,85 pour le *buy-and-hold*, avec un intervalle de confiance qui inclut zéro.

Ces résultats sont compatibles avec l'efficience du marché au sens faible. La démarche,

fondée sur un découpage chronologique, une référence naïve, un nombre de modèles déclaré à l'avance, un jeu de test utilisé une seule fois et un test de permutation, montre qu'il est possible de conclure honnêtement à l'absence d'un effet, plutôt que de chercher à tout prix une configuration qui semble battre le marché.

Références

— Fama, E. F. (1970). Efficient Capital Markets : A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383–417.

— Federal Reserve Bank of St. Louis, FRED : série SP500 (S&P 500), `https://fred.stlouisfed.org/series/SP500`

— Pedregosa et al. (2011). Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.